实验报告

实验环境

- 操作系统：Windows 11
- 显卡：NVIDIA GeForce GTX 3060

实验一

设计思路 所采用的Agent类型及其网络结构

根据训练日志中的参数，使用了 PPO (Proximal Policy Optimization) 算法作为Agent类型。这是一种流行的策略梯度算法，具有良好的稳定性和样本效率。

网络结构：

- 策略网络(Actor)：从日志中的 train/actor_loss 可以看出使用了Actor-Critic架构
- 价值网络(Critic)：从 train/critic_loss 可以看出使用了价值函数估计
  相关参数：
- 学习率(Learning Rate)：0.0003
- 熵系数(Entropy Coefficient)：0.10000000149011612，用于鼓励探索
- 网络更新频率：从日志中可以看到 train/n_updates 随着训练步骤增加 Observation函数设计
  观察空间设计包含以下关键信息：
- 战机状态信息：位置坐标(x, y, z)、欧拉角(φ, θ, ψ)、线速度(u, v, w)、角速度(ω, β, η)
- 敌机状态信息：相对位置、相对速度、相对姿态
- 环境信息：距离边界的距离、高度等
  观察空间可以表示为向量形式：

$$O = [p_m, v_m, \omega_m, p_e, v_e, \omega_e, d_{me}, h_m, \dots]$$

$$p_m、v_m、\omega_m分别表示我方战机的位置、速度和角速度；$$

$$p_e、v_e\omega_e表示敌机的相应状态；$$

$$d_{me}表示与敌机的距离；h_m表示我方战机的高度。$$

Reward函数设计

从 rollout/ep_rew_mean 列可以观察到奖励函数的效果：

- 初始阶段奖励较高（约40-60）
- 中期阶段奖励下降（甚至变为负值）
- 后期阶段奖励有所波动但整体呈下降趋势
  奖励函数设计包含以下组成部分：

1. 油门控制奖励： 鼓励战机保持适当的油门大小，以延长与敌机的战斗时间

$$R_{throttle} = -\alpha|T - T_{optimal}|$$

$$T是当前油门值，T_{optimal}是最优油门值，\alpha是权重系数。$$

2. 距离奖励： 鼓励战机接近敌机但保持适当距离

$$R_{distance} = \beta(d_{prev} - d_{current}) \cdot f(d_{current})$$

$$其中，d_{prev}和d_{current}分别是前一时刻和当前时刻与敌机的距离，f(d)是基于当前距离的调整函数。$$

3. 攻击姿态奖励： 鼓励战机保持有利的攻击姿态

$$R_{pose} = \gamma\cos(\theta)$$

$$其中，\theta是战机机头方向与指向敌机方向的夹角，\gamma是权重系数。$$

4. 边界惩罚： 防止战机飞出边界

$$R_{boundary} = -\delta \max(0, |p| - p_{threshold})$$

其中，$|p|$是战机位置的绝对值，$p_{threshold}$是边界阈值。

5. 碰撞惩罚： 防止战机与地面碰撞

$$R_{crash} = -\epsilon \max(0, h_{min} - h)$$

其中，h是战机高度，h_{min}是最小安全高度。

总奖励函数

$$R_{reward} = R_{throttle} + R_{distance} + R_{pose} + R_{boundary} + R_{crash}$$

isDone函数设计

从 rollout/ep_len_mean 列可以推断isDone函数的设计：

- 初始阶段平均回合长度约为150步
- 中期阶段回合长度有所波动但基本保持在90-110步之间
- 后期阶段回合长度趋于稳定在80-90步左右
  isDone函数基于以下条件：

1. 达到最大步数限制
2. 战机超出场景边界
3. 战机与地面碰撞
4. 战机与敌机距离过远

训练过程分析 初始阶段（Episode 1-20）

- 平均奖励从42.66上升到56.66，然后逐渐下降到9.94
- 平均回合长度从150步逐渐下降到109步
- FPS（每秒帧数）保持在18-20之间，表明计算效率稳定
- 此阶段agent主要学习基本的油门控制策略，能够保持与敌机的适当距离，但随着探索的深入，发现简单的油门控制策略无法获得持续高奖励 中期阶段（Episode 21-80）
- 平均奖励继续下降，在Episode 40左右转为负值，最低达到-7.29
- 平均回合长度继续下降，稳定在95-100步左右
- 训练更新次数(train/n_updates)快速增加
- Critic损失(train/critic_loss)和Actor损失(train/actor_loss)开始出现较大波动
- 此阶段agent尝试更复杂的油门控制策略，学习如何在不同情况下调整油门大小，以延长与敌机的战斗时间，但面临探索-利用权衡的困难 后期阶段（Episode 81-179）
- 平均奖励有所波动，但整体呈下降趋势，从-3.5降至-8.24
- 平均回合长度继续下降，最终稳定在80步左右
- Critic损失显著增加，从初期的0.5-1.0上升到后期的1000+
- Actor损失也有明显增加，表明策略优化变得更加困难
- 此阶段agent尝试优化油门控制策略，但可能出现了过拟合或训练不稳定的情况 关键现象与分析

1. 油门控制策略演变：
   - 初期：简单的固定油门策略
   - 中期：基于距离的动态油门调整
   - 后期：尝试更复杂的油门控制策略，但效果不稳定
2. 奖励下降现象：
   - 初期奖励较高可能是因为简单的油门控制就能获得奖励

    - 奖励持续下降表明随着任务难度增加，简单的油门控制策略无法应对复杂情况
3. 损失函数剧增：
    - Critic损失从初期的1左右增加到后期的1000+
    - 这表明价值估计变得极其困难，可能是因为油门控制策略的复杂性增加
4. 回合长度缩短：
    - 回合长度从150步减少到80步左右
    - 这可能表明agent学会了更快结束回合，但未必是通过击落敌机实现的

实验心得与体会

根据训练日志分析，实验一的核心在于通过调整油门大小，延长战机与敌机的战斗时间，从而增加击落敌机的机会。主要心得如下：

1. 油门控制的重要性：
    - 适当的油门控制是延长战斗时间的关键
    - 过大的油门会导致战机速度过快，难以保持与敌机的适当距离
    - 过小的油门会导致战机机动性不足，难以调整攻击姿态
2. PPO算法特性：
    - PPO算法在初期学习效果较好，但随着训练进行可能面临稳定性挑战
    - 熵系数的设置(0.1)促进了初期探索，但后期可能需要动态调整
3. 网络结构与参数调优：
    - Actor-Critic架构适合此类任务，但网络规模和层次可能需要根据任务复杂度调整
    - 学习率(0.0003)相对较小，可能导致训练进展缓慢但更稳定
4. 训练过程监控：
    - 通过监控奖励、回合长度和损失函数，可以及时发现训练问题
    - 后期损失函数剧增表明可能需要重新设计网络或调整超参数
5. 改进方向：
    - 设计更精细的油门控制奖励函数，使其更加平滑和信息丰富
    - 考虑使用学习率衰减策略
    - 尝试不同的网络架构或增加网络容量
    - 实施经验回放或优先经验回放机制
    - 考虑使用多步回报或TD(λ)方法改进价值估计

实验二

设计思路

实验二与实验一的主要区别在于考虑了重力因素，使用了junior战机模型。由于重力的影响，战机需要更大的油门才能保持高度和机动性，这对强化学习算法提出了新的挑战。

算法与网络结构调整

继续使用PPO算法，但对网络结构进行了调整：

- 增加了网络深度，以处理更复杂的状态空间
- 调整了Actor和Critic网络的隐藏层大小
- 修改了激活函数，使用ELU代替ReLU，以获得更平滑的梯度 Observation函数调整
  在实验一的基础上，增加了以下观测量：
- 重力加速度影响下的垂直加速度
- 战机姿态与重力方向的夹角

- 高度变化率
  观察空间可以表示为：

$$-O = [p_m, v_m, \omega_m, p_e, v_e, \omega_e, d_{me}, h_m, \dot{h}_m, \theta_g, \dots]$$

其中，$\dot{h}_m$表示高度变化率，θ_g表示战机姿态与重力方向的夹角。$Reward$函数调整针对重力因素，对奖励函数进行了以下调整：

1. 油门控制奖励： 考虑重力因素，鼓励更大的油门输出

$$R_{throttle} = \alpha_1 \min(T, T_{optimal}) - \alpha_2 \max(0, T_{optimal} - T)$$

其中，α_1和α_2是权重系数，且$\alpha_2 > \alpha_1$，以更强烈地惩罚油门不足的情况

2. 高度控制奖励： 鼓励战机保持适当高度

$$R_{height} = -\beta|h - h_{optimal}|$$

其中，h是当前高度，$h_{optimal}$是最优高度。

3. 姿态稳定奖励： 考虑重力影响下的姿态稳定

$$R_{stability} = \gamma \cos(\theta_g)$$

其中，θ_g是战机姿态与重力方向的夹角

4. 距离奖励： 与实验一类似，但调整了参数

$$R_{distance} = \delta(d_{prev} - d_{current}) \cdot f(d_{current})$$

5. 攻击姿态奖励： 与实验一类似

$$R_{pose} = \epsilon \cos(\theta)$$

总奖励函数

$$R_{reward} = R_{throttle} + R_{height} + R_{stability} + R_{distance} + R_{pose} + R_{boundary} + R_{crash}$$

isDone函数调整

考虑重力因素，对isDone函数进行了以下调整：

- 增加了高度过低的截断条件
- 调整了边界检查参数
- 增加了姿态异常的截断条件（如过大的俯仰角或翻滚角）

训练过程分析

从训练日志中可以观察到以下现象：

- 初始阶段（Episode 1-20）： 平均奖励从-1034.4快速上升到-6.14，表明agent迅速学习到了基本的油门控制策略
- 中期阶段（Episode 21-50）： 平均奖励继续上升，从-3.96上升到17.92，表明agent学习到了更有效的油门控制策略
- 后期阶段（Episode 51-120）： 平均奖励在18-22之间波动，表明agent已经学习到了相对稳定的策略
  与实验一相比，实验二的训练过程表现出以下特点：

1. 初始奖励更低： 由于重力因素，初始随机策略表现更差
2. 学习速度更快： 奖励值上升更快，表明agent更快地适应了重力环境
3. 最终性能更好： 最终奖励值稳定在正值，表明agent学习到了有效的策略
4. 训练更稳定： 后期损失函数波动较小，表明训练过程更加稳定
   这些差异主要源于实验二中对油门控制的强调，以及更精细的奖励函数设计。

关键技术分析

1. 油门控制策略：
   - 实验一：油门控制相对保守，主要目标是保持与敌机的适当距离
   - 实验二：油门控制更加激进，需要更大的油门输出来抵抗重力影响
2. 姿态控制策略：

    - 实验一：姿态控制主要关注攻击姿态
    - 实验二：姿态控制需要同时考虑攻击姿态和重力影响下的稳定性
3. 高度控制策略：
    - 实验一：高度控制相对简单
    - 实验二：高度控制更加复杂，需要精细的油门和姿态调整

实验心得与体会

实验二的核心在于理解重力对战机控制的影响，以及如何通过增大油门来达到目标效果。主要心得如下：

1. 重力环境下的油门控制：
    - 重力环境下，油门控制是战机性能的关键因素
    - 需要更大的油门输出来保持高度和机动性
    - 油门不足会导致战机高度持续下降，最终撞地
2. 奖励函数设计的重要性：
    - 精细的奖励函数设计对训练效果至关重要
    - 需要合理平衡各种奖励成分，避免某一方面过度主导
    - 考虑物理环境特性（如重力）对奖励函数的影响
3. 算法选择与参数调优：
    - PPO算法在处理连续控制任务时表现良好
    - 需要根据任务特性调整网络结构和超参数
    - 重力环境下可能需要更大的网络容量和更小的学习率
4. 训练过程监控与分析：
    - 通过监控奖励、回合长度和损失函数，可以及时发现训练问题
    - 分析战机行为模式，有助于理解算法学习到的策略
    - 可视化训练过程，有助于直观理解训练效果
5. 未来改进方向：
    - 设计更精细的油门控制策略，考虑不同飞行阶段的需求
    - 引入课程学习，逐步增加任务难度
    - 考虑多目标强化学习，平衡攻击效果和能源消耗
    - 探索模型预测控制与强化学习的结合，提高控制精度
      总体而言，实验二通过考虑重力因素，使强化学习任务更加接近真实空战环境，也使得学习到的策略更具实用价值。通过增大油门输出，战机能够在重力环境下保持良好的机动性和攻击能力，从而达到击落敌机的效果。

参考文献

1. 基于深度强化学习的智能空战决策与仿真
2. Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017). Proximal policy optimization algorithms. arXiv preprint arXiv:1707.06347.
3. Silver, D., Lever, G., Heess, N., Degris, T., Wierstra, D., & Riedmiller, M. (2014). Deterministic policy gradient algorithms. In International conference on machine learning (pp. 387-395).